

PROYECTO GRUPAL (PG)

Caso integrador de Analítica de Datos: AndinaRetail S.A.C.

Escuela Profesional de Ingeniería de Software — Facultad de Ingeniería de Sistemas e Informática
Universidad Nacional Mayor de San Marcos
Ciclo X — Semestre Académico 2026-1 — Docente: Mg. Juan Gamarra Moreno

1. Información general del proyecto

El presente documento contiene las instrucciones oficiales para el desarrollo del Proyecto Grupal (PG) de la asignatura Analítica de Datos. El PG es un trabajo aplicado, colaborativo y de carácter integrador que recorre el ciclo de vida completo de un proyecto de analítica — desde la exploración estadística de los datos hasta la generación de recomendaciones prescriptivas y su comunicación mediante tableros de control— sobre el caso de una empresa ficticia para la cual el equipo deberá generar datos sintéticos.

Aspecto	Detalle
Asignatura	Analítica de Datos (código 2011104, Plan 2018)
Escuela / Facultad	E.P. Ingeniería de Software / FISI – UNMSM
Ciclo y semestre	Ciclo X – Semestre 2026-1
Modalidad de trabajo	Grupal (mínimo 4 y máximo 6 integrantes)
Naturaleza	Teórico-práctico, integrador y progresivo (5 partes)
Peso en la evaluación	El PG equivale al 40% de la Evaluación Continua ($EC = PG \cdot 0.40 + (TA \cdot (\%Asist. + 0.08)) \cdot 0.60$)
Herramientas obligatorias	Python (Jupyter Notebook) para las Partes 1 a 4; Microsoft Power BI para la Parte 5
Entregable global	Repositorio con 4 notebooks, archivo .pbix, datos sintéticos, bitácora de prompts y presentación final

2. Propósito, competencias y resultados de aprendizaje

El proyecto desarrolla la competencia técnica de la asignatura y articula los cuatro resultados de aprendizaje (RA) del sílabo. Cada parte del PG aporta evidencia directa de uno o más RA, tal como se resume a continuación.

Competencia (CT 12.3, nivel avanzado): Implementa soluciones de software para la toma de decisiones gerenciales utilizando las metodologías y estándares internacionales de calidad y de la ciencia de los datos, con una actitud ética y responsabilidad social.

RA	Descripción	Parte(s) del PG que lo evidencia
RA1	Entiende los principios clave de la analítica de datos y enfrenta los desafíos del entorno masivo de datos.	Partes 1 y 2
RA2	Aplica técnicas estadísticas descriptivas e inferenciales y desarrolla modelos predictivos.	Partes 1, 2 y 3
RA3	Desarrolla modelos prescriptivos integrando las mejores prácticas de modelado analítico.	Parte 4
RA4	Comprende las consideraciones éticas en el manejo de datos, visualiza y presenta resultados analíticos.	Partes 4 y 5

2.1 Objetivo general

Diseñar y ejecutar una solución integral de analítica de datos para una empresa ficticia, aplicando técnicas estadísticas, modelos descriptivos, diagnósticos, predictivos y prescriptivos sobre datos sintéticos generados por el equipo, y comunicando los hallazgos mediante tableros de control que apoyen la toma de decisiones gerenciales.

2.2 Objetivos específicos

- Generar un conjunto de datos sintéticos coherente, documentado y reproducible que represente la operación de la empresa ficticia.
- Aplicar técnicas estadísticas descriptivas e inferenciales para caracterizar el negocio (Parte 1).
- Construir modelos descriptivos y diagnósticos que expliquen el comportamiento histórico y sus causas (Parte 2).
- Desarrollar y evaluar modelos predictivos para anticipar comportamientos relevantes del negocio (Parte 3).
- Formular y resolver modelos prescriptivos de optimización que mejoren objetivos específicos del negocio (Parte 4).
- Diseñar tableros de control en Power BI que integren y comuniquen los resultados de las partes anteriores (Parte 5).
- Documentar de forma trazable los prompts de IA generativa empleados, incluyendo los usados para generar los datos sintéticos.

3. Conformación de equipos y roles

Cada equipo estará conformado por un **mínimo de 4 y un máximo de 6 integrantes**. La distribución de roles es obligatoria; un integrante puede asumir más de un rol cuando el equipo sea de 4 personas. Todos los integrantes deben participar en el componente técnico y en la presentación final.

Rol	Responsabilidades principales
Líder de proyecto / Data PM	Coordina el cronograma, asegura la integración de las 5 partes, gestiona el repositorio y la bitácora de prompts, y consolida los entregables.
Ingeniero(a) de datos	Diseña y ejecuta la generación de datos sintéticos, el diccionario de datos y la limpieza/preparación; vela por la reproducibilidad (semillas).
Analista estadístico / descriptivo	Lidera la Parte 1 (estadística) y la Parte 2 (descriptivo y diagnóstico), garantizando interpretaciones correctas.
Científico(a) de datos	Lidera la Parte 3 (modelos predictivos) y apoya la Parte 4 (prescriptivos): modelado, validación y métricas.
Analista de optimización / BI	Lidera la Parte 4 (prescriptivos) y la Parte 5 (tableros en Power BI), conectando los resultados con la decisión de negocio.

Nota: la asignación de roles no exime de la corresponsabilidad. La nota individual puede ajustarse según la participación evidenciada (commits del repositorio, bitácora y defensa oral).

4. Descripción del caso: AndinaRetail S.A.C. (empresa ficticia)

AndinaRetail S.A.C. es una empresa ficticia del sector retail omnicanal en el Perú. Opera una cadena de tiendas físicas y un canal digital (web y aplicación móvil) en cinco ciudades: Lima, Arequipa, Trujillo, Cusco y Piura. Su catálogo abarca seis categorías: Abarrotes, Bebidas, Limpieza, Cuidado Personal, Electrohogar y Hogar. La empresa atiende a clientes minoristas y registra cada transacción a nivel de línea de venta.

La Gerencia General ha solicitado al área de analítica un estudio integral para responder a cuatro preocupaciones estratégicas: (1) comprender el comportamiento de ventas y de clientes; (2) diagnosticar la caída de margen observada en algunas plazas y el aumento de la inactividad de clientes; (3) anticipar la demanda y la fuga (churn) de clientes; y (4) optimizar el inventario, los descuentos y la operación, comunicando todo ello en tableros ejecutivos.

Importante: la empresa es ficticia y todos los datos deben ser sintéticos. No está permitido usar datos reales de personas o empresas. El equipo puede personalizar el nombre, el rubro o el alcance de la empresa, siempre que el caso permita desarrollar coherentemente las cinco partes y la generación de datos sintéticos quede documentada.

4.1 Preguntas de negocio que el proyecto debe responder

- ¿Cómo se distribuyen las ventas, los tickets y los clientes? ¿Existen diferencias estadísticamente significativas entre canales, ciudades o categorías? (Parte 1)
- ¿Qué patrones históricos y estacionales explican el desempeño? ¿Qué segmentos de clientes existen y por qué cae el margen en ciertas plazas? (Parte 2)
- ¿Qué demanda se espera por categoría y periodo? ¿Qué clientes tienen mayor probabilidad de volverse inactivos? (Parte 3)
- ¿Cuánto inventario mantener y qué política de descuentos aplicar para maximizar el margen cumpliendo restricciones operativas? (Parte 4)
- ¿Cómo monitorear todo lo anterior en tableros que orienten la decisión gerencial? (Parte 5)

5. Generación de datos sintéticos

La generación de datos sintéticos es un requisito central del proyecto y debe ser reproducible. El equipo debe entregar un script en Python que cree los datos a partir de una semilla fija, junto con un diccionario de datos. Se sugiere usar las librerías pandas, numpy y Faker (locale es_PE). Como mínimo deben generarse las siguientes tablas; el equipo puede ampliarlas si lo justifica.

Dataset (archivo)	Campos principales	Volumen sugerido
tiendas.csv	id_tienda, nombre, ciudad, región, tipo (Física/Virtual), área_m2, fecha_apertura	10–15 tiendas
productos.csv	id_producto, nombre, categoría, subcategoría, marca, precio_lista, costo_unitario, fecha_alta	600–1000 productos
clientes.csv	id_cliente, nombre, edad, género, ciudad, distrito, fecha_registro, canal_preferido, segmento	10 000–20 000 clientes
ventas.csv	id_venta, fecha, id_cliente, id_tienda, id_producto, cantidad, precio_unitario, descuento_pct, monto_total, canal, método_pago	150 000–300 000 líneas

Dataset (archivo)	Campos principales	Volumen sugerido
inventario.csv	id_producto, id_tienda, periodo (AAAA-MM), stock_inicial, unidades_vendidas, reabastecimiento, stock_final, costo_almacenamiento	snapshot mensual

5.1 Patrones que los datos deben incorporar (para habilitar el análisis)

Para que las partes 2, 3 y 4 produzcan resultados con sentido, los datos sintéticos deben contener señales y patrones controlados. El equipo debe documentar estos patrones en el diccionario de datos.

- Estacionalidad: picos de venta en julio (Fiestas Patrias) y diciembre (Navidad); tendencia creciente del canal digital en el tiempo.
- Patrón diagnóstico: a partir del segundo trimestre de 2025, las tiendas de una ciudad (p. ej. Trujillo) muestran caída de margen (mayor descuento promedio y mayor costo de almacenamiento).
- Patrón de fuga (churn): se considera inactivo al cliente sin compras en los últimos 90 días; la probabilidad de inactividad aumenta con baja frecuencia histórica y alta antigüedad de la última compra, de modo que un modelo pueda aprenderlo.
- Demanda predecible: la cantidad vendida por categoría depende del mes, el canal y el descuento, con ruido aleatorio moderado.
- Calidad de datos: incluir entre 1% y 3% de valores faltantes y algunos outliers controlados, para exigir limpieza y preparación de datos.

Reproducibilidad obligatoria: fijar semillas (`numpy.random.seed`, `random.seed` y `Faker.seed`) y entregar el script de generación junto con los CSV resultantes. El prompt utilizado para generar los datos debe registrarse en la bitácora (ver Sección 8).

6. Estructura del proyecto: las cinco partes

El proyecto se desarrolla en cinco partes secuenciales. Las Partes 1 a 4 se entregan como notebooks de Python (.ipynb) bien documentados (celdas de texto en Markdown que expliquen objetivo, método, resultado e interpretación de negocio). La Parte 5 se entrega como archivo de Power BI (.pbix) más una exportación en PDF. Cada parte indica su objetivo, las preguntas de negocio que aborda, los pasos a seguir y las técnicas/librerías sugeridas.

6.1 Parte 1 — Notebook de técnicas estadísticas

Objetivo: caracterizar el negocio mediante estadística descriptiva e inferencial, verificando hipótesis sobre los datos de AndinaRetail. (Sílabo, Semana 4; RA1, RA2).

1. Cargar los datos sintéticos y realizar una exploración inicial (estructura, tipos, valores faltantes, outliers).
2. Calcular estadística descriptiva: medidas de tendencia central, dispersión y forma (media, mediana, moda, desviación, asimetría, curtosis) para variables clave (monto, ticket, edad, cantidad).
3. Construir tablas de frecuencias y visualizaciones univariadas y bivariadas (histogramas, boxplots, dispersión).
4. Analizar correlaciones entre variables numéricas (p. ej. descuento vs. cantidad, precio vs. cantidad).

5. Formular y contrastar al menos tres hipótesis con pruebas adecuadas (p. ej. prueba t para ticket promedio entre canales, ANOVA entre ciudades, chi-cuadrado entre categoría y método de pago), verificando supuestos.
6. Calcular intervalos de confianza para indicadores relevantes y redactar las conclusiones de negocio.

Técnicas/librerías sugeridas: pandas, numpy, scipy.stats, matplotlib/seaborn, statsmodels.

Entregable: notebook 01_estadistica.ipynb (Informe 1).

6.2 Parte 2 — Notebook de modelo descriptivo y diagnóstico

Objetivo: explicar el comportamiento histórico (qué pasó) e identificar causas (por qué pasó), generando valor a través del análisis retrospectivo. (Sílabo, Semana 5; RA1, RA2).

1. Construir series de tiempo de ventas y márgenes; identificar tendencias y estacionalidad por canal, ciudad y categoría.
2. Aplicar análisis de Pareto (80/20) para productos, clientes y categorías; identificar los principales contribuyentes.
3. Segmentar clientes con análisis RFM (Recencia, Frecuencia, Valor monetario) y/o clustering (p. ej. K-Means), caracterizando cada segmento.
4. Realizar análisis diagnóstico de la caída de margen: drill-down por ciudad/periodo, comparación de cohortes y descomposición de la variación (precio, descuento, mezcla, costos).
5. Sintetizar hallazgos descriptivos y diagnósticos en conclusiones accionables para la Gerencia.

Técnicas/librerías sugeridas: pandas, numpy, matplotlib/seaborn, scikit-learn (KMeans, StandardScaler), tablas dinámicas. **Entregable:** notebook 02_descriptivo_diagnostico.ipynb (Informe 2).

6.3 Parte 3 — Notebook de modelos predictivos

Objetivo: anticipar comportamientos del negocio mediante modelos predictivos, con preparación de datos, evaluación rigurosa y técnicas avanzadas. (Sílabo, Semanas 6 y 7; RA2).

1. Definir al menos dos problemas predictivos: uno de regresión (p. ej. demanda/ventas por categoría-periodo) y uno de clasificación (p. ej. probabilidad de que un cliente se vuelva inactivo / churn).
2. Preparar los datos: ingeniería de variables, codificación de categóricas, escalamiento, tratamiento de faltantes y partición train/test (con validación cruzada).
3. Entrenar modelos base (p. ej. regresión lineal/logística, árbol de decisión) y modelos avanzados (Random Forest, Gradient Boosting/XGBoost).
4. Optimizar hiperparámetros (GridSearchCV o RandomizedSearchCV) y comparar modelos con métricas adecuadas (regresión: MAE, RMSE, R^2 ; clasificación: exactitud, precisión, recall, F1, AUC-ROC, matriz de confusión).
5. Analizar la importancia de variables (feature importance / SHAP) e interpretar los resultados en términos de negocio.
6. Redactar conclusiones y recomendaciones basadas en las predicciones.

Técnicas/librerías sugeridas: scikit-learn, xgboost, shap, matplotlib/seaborn. **Entregable:** notebook 03_predictivo.ipynb (Informe 3).

6.4 Parte 4 — Notebook de modelos prescriptivos

Objetivo: recomendar la mejor acción mediante optimización y simulación, integrando los hallazgos predictivos. (Sílabo, Semanas 9 y 10; RA3, RA4).

1. Seleccionar al menos un problema de optimización del negocio (p. ej. cuánto inventario reponer por producto-tienda para minimizar costo cumpliendo un nivel de servicio, o qué política de descuento maximiza el margen sujeto a restricciones).
2. Formular el modelo matemático: variables de decisión, función objetivo y restricciones; documentarlo claramente.
3. Implementar y resolver el modelo con una librería de optimización (PuLP o SciPy.optimize).
4. Realizar análisis de escenarios y/o de sensibilidad (what-if); opcionalmente, simular el proceso con SimPy para comparar políticas.
5. Traducir la solución en recomendaciones prescriptivas accionables, conectándolas con las predicciones de la Parte 3 y los diagnósticos de la Parte 2.

Técnicas/librerías sugeridas: PuLP, scipy.optimize, simpy, pandas, numpy. **Entregable:** notebook 04_prescriptivo.ipynb (Informe 4).

6.5 Parte 5 — Tableros de control y visualizaciones (Power BI)

Objetivo: integrar y comunicar los resultados de las partes anteriores en tableros de control que faciliten la toma de decisiones gerenciales. (Sílabo, Semana 15; RA4).

1. Importar los datos a Power BI y construir el modelo de datos (relaciones entre tablas, tabla de calendario).
2. Crear medidas DAX para los KPI clave (ventas, margen, ticket promedio, clientes activos, tasa de inactividad, etc.).
3. Diseñar como mínimo tres páginas de tablero: (a) tablero ejecutivo con KPIs; (b) análisis de ventas por ciudad/categoría/canal/tiempo; (c) clientes y segmentación (RFM/churn). Se recomienda una cuarta página con los resultados predictivos/prescriptivos.
4. Incorporar interactividad: segmentadores (slicers), drill-down/drill-through y marcadores (bookmarks).
5. Aplicar storytelling con datos: títulos claros, jerarquía visual y orientación a la decisión; exportar el tablero a PDF.

Herramienta obligatoria: Microsoft Power BI. **Entregable:** archivo AndinaRetail.pbix más exportación PDF (Informe 5).

7. Documentación y uso de prompts de IA generativa

El uso de herramientas de IA generativa está permitido y se valora cuando es transparente, crítico y reproducible. El equipo debe entregar una bitácora de prompts que registre los prompts más relevantes empleados para estructurar y resolver el proyecto. Es obligatorio incluir el prompt utilizado para generar los datos sintéticos, con el detalle suficiente para reproducir la generación.

7.1 Bitácora de prompts (formato requerido)

Por cada prompt relevante, registrar: identificador, parte del proyecto, objetivo, prompt utilizado (texto), herramienta/modelo, salida obtenida y la validación o ajuste que realizó el equipo sobre esa salida. Se sugiere la siguiente plantilla.

ID	Parte	Objetivo del prompt	Prompt utilizado (texto)	Salida y validación
P-01	Datos	Generar el dataset sintético de AndinaRetail	Ver prompt completo en la Sección 7.2	Script ejecutado; se verificó esquema, volúmenes y patrones (estacionalidad, churn)
P-02	Parte 3	Comparar modelos de churn	"Sugiere un pipeline de scikit-learn para..."	Se adaptó el código y se validaron las métricas manualmente

7.2 Prompt obligatorio de generación de datos sintéticos (ejemplo de referencia)

El siguiente prompt es un ejemplo del nivel de detalle requerido. El equipo debe adaptarlo a su caso y registrar la versión final efectivamente utilizada en la bitácora.

```
Actúa como ingeniero de datos senior. Genera un único script de Python (3.11) que use pandas, numpy y Faker (locale 'es_PE'). Fija las semillas numpy.random.seed(2026), random.seed(2026) y Faker.seed(2026) para reproducibilidad. Crea los datos sintéticos de la empresa ficticia 'AndinaRetail S.A.C.' (retail omnicanal peruano con tiendas físicas y canal digital) y expórtalos como CSV en la carpeta 'datos/'. Genera: 1) tiendas.csv (12 tiendas): id_tienda, nombre, ciudad (Lima, Arequipa, Trujillo, Cusco, Piura), region, tipo (Física/Virtual), area_m2, fecha_apertura. 2) productos.csv (800): id_producto, nombre, categoría (Abarrotes, Bebidas, Limpieza, Cuidado Personal, Electrohogar, Hogar), subcategoría, marca, precio_lista, costo_unitario (60-80% del precio), fecha_alta. 3) clientes.csv (15000): id_cliente, nombre, edad (normal media 38, desv. 12, truncada 18-80), genero, ciudad, distrito, fecha_registro (2022-2025), canal_preferido, segmento. 4) ventas.csv (~250000 líneas, 2023-01-01 a 2025-12-31): id_venta, fecha, id_cliente, id_tienda, id_producto, cantidad (1-8, sesgada a 1-2), precio_unitario, descuento_pct (0-35%), monto_total, canal (Tienda/Web/App), metodo_pago. 5) inventario.csv (snapshot mensual por producto-tienda): id_producto, id_tienda, periodo (AAAA-MM), stock_inicial, unidades_vendidas, reabastecimiento, stock_final, costo_almacenamiento_unitario. Incorpora estos patrones: estacionalidad (picos en julio y diciembre) y crecimiento del canal digital; desde 2025-Q2, caída de margen en Trujillo (mayor descuento y costo de almacenamiento); churn = sin compras en 90 días al 2025-12-31, con mayor probabilidad cuando la frecuencia es baja y la última compra es antigua; la cantidad por categoría
```

depende de mes, canal y descuento con ruido moderado; incluye 1-3% de faltantes y algunos outliers. Entrega además data_dictionary.md describiendo cada tabla, campo, tipo y dominio. Todos los nombres deben ser ficticios; no uses datos reales.

7.3 Ejemplos de prompts por parte

- Parte 1: “A partir de este DataFrame de ventas, propón tres hipótesis contrastables y el test estadístico adecuado para cada una, indicando los supuestos a verificar.”
- Parte 2: “Explica cómo construir una segmentación RFM en pandas y cómo interpretar cada segmento para un retail.”
- Parte 3: “Diseña un pipeline de scikit-learn para predecir churn con validación cruzada y comparación de Random Forest vs. Gradient Boosting, reportando AUC y F1.”
- Parte 4: “Formula como programación lineal en PuLP el problema de reponer inventario minimizando costos con un nivel de servicio mínimo del 95%.”
- Parte 5: “Sugiere medidas DAX para ventas, margen, ticket promedio y tasa de inactividad, y una estructura de tres páginas de tablero ejecutivo.”

Uso responsable: toda salida de IA debe ser revisada, comprendida y validada por el equipo. Copiar resultados sin verificación es considerado una mala práctica y afecta la evaluación (ver Sección 13).

8. Ruta de trabajo paso a paso y cronograma sugerido

Se recomienda alinear el avance del proyecto con el desarrollo de las sesiones. La entrega es progresiva: cada parte se consolida conforme se cubre el tema correspondiente en clase.

Hito / Semana	Actividad	Entregable parcial
Semanas 1–3	Conformar el equipo, definir el caso y generar los datos sintéticos con su diccionario.	Repositorio inicial + datos sintéticos + diccionario
Semana 4	Desarrollar la Parte 1 (estadística).	Notebook 01_estadistica.ipynb
Semana 5	Desarrollar la Parte 2 (descriptivo y diagnóstico).	Notebook 02_descriptivo_diagnostico.ipynb
Semanas 6–7	Desarrollar la Parte 3 (predictivos).	Notebook 03_predictivo.ipynb
Semanas 9–10	Desarrollar la Parte 4 (prescriptivos).	Notebook 04_prescriptivo.ipynb
Semanas 12–15	Desarrollar la Parte 5 (Power BI), integrar y preparar la presentación.	AndinaRetail.pbix + PDF + bitácora de prompts
Semana 15	Presentación y defensa del proyecto integrado.	Presentación final + entrega global

Nota: las fechas exactas de entrega de cada parte se publicarán en el Aula Virtual. El equipo debe respetar los plazos indicados allí.

9. Normas de entrega y formato

- Repositorio: entregar el proyecto en un repositorio (GitHub o carpeta en la nube) con la estructura de carpetas del Anexo A.
- Notebooks: en formato .ipynb, ejecutados (con salidas visibles), documentados con celdas Markdown (objetivo, método, resultado, interpretación) y reproducibles desde los datos sintéticos.
- Power BI: archivo .pbix más exportación en PDF de todas las páginas del tablero.

- Datos: incluir el script de generación, los CSV resultantes y el diccionario de datos (data_dictionary.md).
- Bitácora de prompts: documento (Markdown o PDF) con la plantilla de la Sección 7.
- Presentación: archivo de diapositivas para la defensa oral (máximo 12 minutos por equipo).
- Nomenclatura de archivos: usar prefijos numéricos (01_, 02_, ...) y nombres en minúsculas sin tildes ni espacios.
- Originalidad: el proyecto es original del equipo; cualquier fuente externa debe citarse y todo uso de IA debe constar en la bitácora.

10. Rúbricas detalladas de evaluación

La calificación del Proyecto Grupal (sobre 100 puntos) se distribuye entre las cinco partes y dos componentes transversales (bitácora de prompts y presentación final). Cada criterio tiene un puntaje máximo y se evalúa según cuatro niveles de desempeño.

10.1 Escala de niveles y distribución de pesos

Cada criterio se califica en uno de cuatro niveles. El porcentaje del puntaje máximo del criterio que se otorga según el nivel es: Excelente = 100%, Bueno = 75%, Regular = 50%, Deficiente = 25% o menos.

Componente evaluado	Puntaje máximo	RA asociado
Parte 1 — Técnicas estadísticas	15	RA1, RA2
Parte 2 — Descriptivo y diagnóstico	15	RA1, RA2
Parte 3 — Modelos predictivos	20	RA2
Parte 4 — Modelos prescriptivos	20	RA3
Parte 5 — Tableros de control (Power BI)	15	RA4
Bitácora de prompts y reproducibilidad	5	Transversal
Presentación final y defensa	10	Transversal
TOTAL	100	—

10.2 Rúbrica — Parte 1: Técnicas estadísticas (15 pts)

Criterio (puntaje)	Excelente	Bueno	Regular	Deficiente
Datos sintéticos pertinentes y reproducibles (3)	Script reproducible (semilla), esquema completo y patrones documentados.	Reproducible, esquema casi completo, documentación parcial.	Generados pero sin semilla o esquema incompleto.	Ausentes o no reproducibles.
Estadística descriptiva (3)	Tendencia, dispersión y forma; tablas y gráficos correctos e interpretados.	Medidas y gráficos correctos con interpretación limitada.	Cálculos básicos con errores menores o sin interpretar.	Ausente o incorrecta.
Inferencia y pruebas de hipótesis (4)	Hipótesis bien formuladas, supuestos verificados, pruebas e	Pruebas pertinentes e interpretadas, sin verificar todos los supuestos.	Alguna prueba con interpretación deficiente.	No aplica inferencia o la interpreta mal.

Criterio (puntaje)	Excelente	Bueno	Regular	Deficiente
	intervalos correctos e interpretados.			
Interpretación de negocio (3)	Conclusiones claras, accionables y vinculadas a AndinaRetail.	Conclusiones correctas con vínculo parcial al negocio.	Conclusiones genéricas o débiles.	Sin conclusiones o desconectadas.
Calidad del notebook (2)	Ordenado, documentado en Markdown y reproducible de inicio a fin.	Documentado y ejecutable con detalles menores.	Poco documentado o con errores de ejecución.	Desordenado o no ejecutable.

10.3 Rúbrica — Parte 2: Descriptivo y diagnóstico (15 pts)

Criterio (puntaje)	Excelente	Bueno	Regular	Deficiente
Análisis retrospectivo y estacionalidad (3)	Series de tiempo claras; tendencia y estacionalidad bien identificadas.	Tendencia/estacionalidad identificadas con análisis limitado.	Análisis temporal superficial.	Ausente o incorrecto.
Identificación de patrones (3)	Pareto y rankings correctos, bien interpretados para la decisión.	Patrones correctos con interpretación parcial.	Patrones básicos sin interpretar.	Ausente o incorrecto.
Segmentación RFM / clustering (4)	Segmentación rigurosa, validada y caracterizada por segmento.	Segmentación correcta con caracterización limitada.	Segmentación con errores o sin caracterizar.	No realizada o incorrecta.
Análisis diagnóstico (3)	Causa raíz con drill-down/cohortes y descomposición de la variación.	Diagnóstico correcto con profundidad parcial.	Diagnóstico superficial.	Sin diagnóstico.
Calidad del notebook (2)	Ordenado, documentado y reproducible.	Documentado y ejecutable con detalles menores.	Poco documentado o con errores.	Desordenado o no ejecutable.

10.4 Rúbrica — Parte 3: Modelos predictivos (20 pts)

Criterio (puntaje)	Excelente	Bueno	Regular	Deficiente
Preparación y selección de variables (3)	Ingeniería de variables, codificación y partición correctas y justificadas.	Preparación correcta con justificación parcial.	Preparación básica con errores.	Inadecuada o ausente.
Modelado predictivo (5)	Modelos base y avanzados bien aplicados a problemas de regresión y clasificación.	Modelos correctos cubriendo un tipo de problema con detalles menores.	Modelos con errores de aplicación.	Modelado ausente o incorrecto.
Evaluación de modelos (5)	Métricas adecuadas, validación cruzada y comparación rigurosa.	Métricas correctas con validación parcial.	Evaluación incompleta o mal interpretada.	Sin evaluación válida.
Técnicas avanzadas (4)	Ensembles y optimización de hiperparámetros aplicados y justificados.	Aplica una técnica avanzada correctamente.	Intento con errores.	No aplica técnicas avanzadas.

Criterio (puntaje)	Excelente	Bueno	Regular	Deficiente
Interpretabilidad y conclusiones (3)	Importancia de variables y conclusiones de negocio claras.	Interpretación correcta con vínculo parcial.	Interpretación débil.	Ausente.

10.5 Rúbrica — Parte 4: Modelos prescriptivos (20 pts)

Criterio (puntaje)	Excelente	Bueno	Regular	Deficiente
Formulación del problema (5)	Variables, función objetivo y restricciones correctas y bien documentadas.	Formulación correcta con documentación parcial.	Formulación con errores conceptuales.	Ausente o incorrecta.
Implementación y solución (5)	Modelo resuelto correctamente con PuLP/SciPy; solución válida.	Resuelto con detalles menores.	Implementación con errores o solución dudosa.	No resuelto.
Análisis de escenarios / sensibilidad (4)	What-if y/o simulación SimPy comparando políticas con rigor.	Análisis de escenarios correcto pero limitado.	Escenarios superficiales.	Ausente.
Recomendaciones prescriptivas (4)	Accionables y conectadas con las Partes 2 y 3.	Recomendaciones correctas con conexión parcial.	Recomendaciones genéricas.	Ausentes.
Calidad del notebook (2)	Ordenado, documentado y reproducible.	Ejecutable con detalles menores.	Poco documentado o con errores.	No ejecutable.

10.6 Rúbrica — Parte 5: Tableros de control en Power BI (15 pts)

Criterio (puntaje)	Excelente	Bueno	Regular	Deficiente
Modelo de datos y medidas DAX (4)	Modelo relacional correcto, calendario y medidas DAX precisas.	Modelo y medidas correctos con detalles menores.	Modelo o medidas con errores.	Inadecuado o ausente.
Diseño y claridad (3)	Tableros limpios, jerarquía visual y títulos claros.	Diseño correcto con mejoras pendientes.	Diseño cargado o confuso.	Deficiente.
Cobertura analítica (4)	Integra de descriptivo a prescriptivo en las páginas del tablero.	Cubre la mayoría de las dimensiones analíticas.	Cobertura parcial.	Mínima o ausente.
Interactividad (2)	Slicers, drill-through y marcadores funcionando.	Interactividad correcta y básica.	Interactividad limitada.	Inexistente.
Storytelling y decisión (2)	Narrativa clara orientada a la decisión gerencial.	Narrativa correcta con foco parcial.	Narrativa débil.	Ausente.

10.7 Rúbrica — Bitácora de prompts y reproducibilidad (5 pts)

Criterio (puntaje)	Excelente	Bueno	Regular	Deficiente
Registro de prompts (2)	Bitácora completa: objetivo, prompt, modelo y salida por cada uso relevante.	Bitácora casi completa.	Registro parcial.	Ausente.

Criterio (puntaje)	Excelente	Bueno	Regular	Deficiente
Prompt de datos detallado (2)	Prompt de generación reproducible y con todos los patrones requeridos.	Prompt reproducible con detalles menores faltantes.	Prompt incompleto.	Ausente o no reproducible.
Validación crítica de la IA (1)	Evidencia de revisión y validación de las salidas.	Validación parcial.	Validación mínima.	Sin validación.

10.8 Rúbrica — Presentación final y defensa (10 pts)

Criterio (puntaje)	Excelente	Bueno	Regular	Deficiente
Claridad y estructura (3)	Presentación ordenada, dentro del tiempo y bien argumentada.	Clara con detalles menores.	Desorganizada o fuera de tiempo.	Confusa.
Dominio técnico y respuestas (4)	Responde con solvencia y comprende a fondo el trabajo.	Responde correctamente la mayoría.	Responde con dificultad.	No domina el contenido.
Participación del equipo (3)	Participación equilibrada de todos los integrantes.	Participación mayoritaria.	Participación desigual.	Solo participa una parte del equipo.

11. Cuadro de autoevaluación

Antes de la entrega, el equipo debe completar el siguiente cuadro de autoevaluación. Para cada criterio, marque el nivel alcanzado (E=Excelente, B=Bueno, R=Regular, D=Deficiente), indique dónde se encuentra la evidencia (notebook/celda, página del tablero, sección de la bitácora) y estime el puntaje según el factor del nivel (E=100%, B=75%, R=50%, D=25%). La suma de la columna de puntaje estimado constituye una proyección de la nota del PG y permite identificar brechas antes de entregar.

Criterio (puntaje máx.)	Pts máx.	Nivel (E/B/R/D)	Evidencia (ubicación)	Pts estimados
P1 · Datos sintéticos reproducibles	3			
P1 · Estadística descriptiva	3			
P1 · Inferencia y pruebas de hipótesis	4			
P1 · Interpretación de negocio	3			
P1 · Calidad del notebook	2			
P2 · Retrospectivo y estacionalidad	3			
P2 · Identificación de patrones	3			
P2 · Segmentación RFM/clustering	4			
P2 · Análisis diagnóstico	3			
P2 · Calidad del notebook	2			
P3 · Preparación y variables	3			

Criterio (puntaje máx.)	Pts máx.	Nivel (E/B/R/D)	Evidencia (ubicación)	Pts estimados
P3 · Modelado predictivo	5			
P3 · Evaluación de modelos	5			
P3 · Técnicas avanzadas	4			
P3 · Interpretabilidad y conclusiones	3			
P4 · Formulación del problema	5			
P4 · Implementación y solución	5			
P4 · Escenarios / sensibilidad	4			
P4 · Recomendaciones prescriptivas	4			
P4 · Calidad del notebook	2			
P5 · Modelo de datos y DAX	4			
P5 · Diseño y claridad	3			
P5 · Cobertura analítica	4			
P5 · Interactividad	2			
P5 · Storytelling y decisión	2			
Bitácora · Registro de prompts	2			
Bitácora · Prompt de datos detallado	2			
Bitácora · Validación crítica de IA	1			
Presentación · Claridad y estructura	3			
Presentación · Dominio y respuestas	4			
Presentación · Participación del equipo	3			
TOTAL ESTIMADO (sobre 100)	100			

Cómo usar este cuadro: si algún criterio queda en nivel Regular o Deficiente, el equipo debe corregirlo antes de entregar. El puntaje estimado se calcula multiplicando el puntaje máximo por el factor del nivel (por ejemplo, un criterio de 4 puntos en nivel Bueno aporta 3 puntos estimados).

12. Lista de cotejo de entregables

Verifique que todos los entregables estén completos antes de la fecha límite.

Entregable	¿Cumple? (Sí/Parcial/No)	Observaciones
Script de generación de datos + CSV + diccionario de datos		
Notebook 01 — Técnicas estadísticas		
Notebook 02 — Descriptivo y diagnóstico		
Notebook 03 — Modelos predictivos		
Notebook 04 — Modelos prescriptivos		

Entregable	¿Cumple? (Sí/Parcial/No)	Observaciones
Archivo Power BI (.pbix) + exportación PDF		
Bitácora de prompts (incluye prompt de datos)		
Presentación final para la defensa		
Repositorio organizado según Anexo A		
Cuadro de autoevaluación completado		

13. Integridad académica y consideraciones éticas

El proyecto debe desarrollarse con honestidad académica y conciencia ética, en coherencia con la competencia de la asignatura. Se consideran los siguientes lineamientos.

- Datos sintéticos y privacidad: está prohibido usar datos reales de personas. Los datos deben ser sintéticos y los nombres ficticios, evidenciando el principio de minimización y protección de datos visto en la Semana 11.
- Transparencia de la IA: todo uso de IA generativa debe registrarse en la bitácora. El equipo debe comprender y validar lo que entrega; no se acepta producción copiada sin verificación.
- Originalidad y citación: el trabajo es propio del equipo; las fuentes externas deben citarse adecuadamente.
- Sesgo y responsabilidad: al interpretar resultados, considerar posibles sesgos de los datos y el impacto de las recomendaciones en las personas y el negocio.
- Corresponsabilidad: todos los integrantes participan; la evaluación puede individualizarse según la evidencia de aporte (repositorio, bitácora y defensa).

Anexo A. Estructura de carpetas sugerida del repositorio

```

proyecto-andinaretail/
├── datos/
│   ├── generar_datos.py          # script reproducible (semilla fija)
│   ├── tiendas.csv
│   ├── productos.csv
│   ├── clientes.csv
│   ├── ventas.csv
│   ├── inventario.csv
│   └── data_dictionary.md        # diccionario de datos
├── notebooks/
│   ├── 01_estadistica.ipynb
│   ├── 02_descriptivo_diagnostico.ipynb
│   ├── 03_predictivo.ipynb
│   └── 04_prescriptivo.ipynb
├── powerbi/
│   ├── AndinaRetail.pbix
│   └── AndinaRetail_tableros.pdf
├── docs/
│   ├── bitacora_prompts.md        # bitácora de prompts (Sección 7)
│   └── autoevaluacion.pdf         # cuadro de autoevaluación (Sección 11)
├── presentacion/
│   └── defensa_final.pdf
└── README.md                     # integrantes, roles y guía de ejecución

```

Cierre: este proyecto integra todo el recorrido de la asignatura. Un buen trabajo no es el que acumula más técnicas, sino el que las articula con claridad para responder a las preguntas de negocio de AndinaRetail y sustentar decisiones. Éxitos en su desarrollo.