

PROYECTO GRUPAL — ANALÍTICA DE DATOS

AndinaRetail S.A.C.

De los datos a la decisión: estadística, diagnóstico, predicción y optimización en retail omnicanal

- Alvarez More Diego — Contexto, Datos y Parte 1 (Estadística)
- Linares Mostacero, Diego Salvador — Parte 2 (Descriptivo y Diagnóstico) y Parte 3 (Predictivo/Prescriptivo)
- Osorio Enzo- 4 , Power BI y Cierre

Agenda

1

Contexto + Datos + Parte 1

El caso AndinaRetail, los 5 datasets, y estadística descriptiva/inferencial

2

Parte 2 — Descriptivo y diagnóstico

Estacionalidad, canal digital, Pareto, segmentación RFM y la caída de margen en Trujillo

3


Partes 3-4 + Power BI + Cierre

Modelos predictivos (demanda, churn), optimización de inventario y recomendaciones finales

Contexto, Datos y Parte 1 — Estadística

AndinaRetail S.A.C. — retail omnicanal peruano

- ▶ Empresa ficticia con tiendas físicas y canal digital (Web/App) en 5 ciudades: Lima, Arequipa, Trujillo, Cusco y Piura.
- ▶ 5 datasets sintéticos y reproducibles (semilla 2026), relacionados por `id_tienda` / `id_producto` / `id_cliente`:
 - 13 tiendas · 800 productos · 15,000 clientes
 - ~250,000 ventas (2023-2025) · ~180,000 filas de inventario mensual
- ▶ Objetivo general: recorrer las 4 etapas de la analítica (descriptiva/inferencial → diagnóstica → predictiva → prescriptiva) sobre un mismo hilo de negocio real: una caída de margen reportada por Gerencia en algunas plazas.



Caracterizar el negocio con estadística descriptiva e inferencial

1

OBJETIVO

Describir cómo se distribuyen ventas, tickets y clientes, y contrastar estadísticamente si existen diferencias entre canales, ciudades y categorías.

2

PREGUNTA DE NEGOCIO

¿Cómo se distribuyen las ventas, los tickets y los clientes? ¿Existen diferencias estadísticamente significativas entre canales, ciudades o categorías?

3

MÉTODO

Estadística descriptiva (tendencia central, dispersión, forma), tablas de frecuencia, correlaciones, 4 pruebas de hipótesis con supuestos verificados, e intervalos de confianza al 95%.

El negocio en 4 números

S/ 121.48

Ticket promedio (mediana S/ 21.98)

61.4%

de ventas por canal Tienda física


46.2%

de ventas concentradas en Lima

47.55%

tasa de inactividad de clientes (IC
95%: 46.75%–48.35%)

Asimetría positiva marcada: la mayoría de compras son pequeñas; una cola de compras grandes eleva el promedio muy por encima de la mediana.




¿Diferencias significativas entre canal, ciudad y categoría?

Hipótesis	Prueba	Resultado	¿Sig. (α=0.05)?	Entonces...
H1 — Ticket: Tienda vs. Digital	t-test	t = -0.891, p = 0.373	No	El ticket promedio en Tienda y en Digital parece distinto en tus datos, pero esa diferencia es tan pequeña que perfectamente pudo salir por azar de la muestra
H2 — Ticket entre 5 ciudades	ANOVA	F = 0.580, p = 0.677	No	Las 5 ciudades tienen tickets promedio parecidos entre sí; ninguna se distingue de forma real.
H3 — Categoría vs. método de pago	Chi-cuadrado	χ² = 18.64, p = 0.230	No	El método de pago que usa la gente no depende de qué categoría de producto está comprando.
H4 — Ticket entre categorías	ANOVA	p < 0.0001	Sí	Una categoría tiene un ticket promedio muy por encima del resto de categorías.

H4 confirmatoria: Electrohogar tiene ticket promedio S/ 543.60 vs. S/ 15-91 en el resto de categorías (mayor precio unitario de electrodomésticos). Supuestos verificados en cada prueba (Levene, frecuencias esperadas ≥5).

Sin diferencias por canal/ciudad; sí por categoría

- ▶ Sin diferencias significativas en el ticket promedio por canal ni por ciudad — descarta el ticket como causa de la caída de margen de Trujillo (Parte 2).
- ▶ Sí hay diferencias reales por categoría, lideradas por Electrohogar — relevante para metas de venta y mix por tienda.
- ▶ Correlaciones descuento/precio vs. cantidad no significativas; la tasa de inactividad (47.55%) anticipa los modelos de churn (Parte 3) y retención (Parte 4).



Parte 2 — Descriptivo y Diagnóstico

Explicar el qué pasó y diagnosticar el por qué

1

OBJETIVO

Explicar el comportamiento histórico de AndinaRetail (series de tiempo, Pareto, segmentación de clientes) e identificar la causa raíz de un problema reportado por Gerencia.

2

PREGUNTA DE NEGOCIO

¿Qué patrones históricos y estacionales explican el desempeño?
¿Qué segmentos de clientes existen y por qué cae el margen en ciertas plazas?



3

MÉTODO

Series de tiempo con descomposición aditiva, análisis de Pareto 80/20, segmentación RFM + K-Means, y drill-down/cohortes/descomposición de causa raíz para el diagnóstico de Trujillo.

Estacionalidad clara y auge sostenido del canal digital

- ▶ Picos de ventas y margen en julio (Fiestas Patrias) y, más marcado, en diciembre (Navidad), cada año (2023-2025).
- ▶ El canal digital (Web + App) pasa de minoritario a dominante en 3 años: de 25.3% (ene-2023) a 55.5% (dic-2025) de los ingresos.
- ▶ Pareto 80/20: un subconjunto acotado de productos concentra la mayoría del ingreso — prioridad para inventario y visibilidad comercial.



Un tercio de los clientes genera 2 de cada 3 soles

Segmento	% clientes	% ingresos	Recencia media	Frecuencia media
Champions	33.6%	67.9%	17.7 días	31.2
Leales	7.3%	11.0%	240.7 días	21.2
Nuevos / Prometedores	10.6%	5.6%	25.8 días	8.7
Regulares	9.1%	3.7%	104.3 días	17.7
En riesgo / Inactivos	39.4%	11.8%	530.6 días	5.3

Validado de forma no supervisada con K-Means (k=4, método del codo): confirma un clúster de alto valor y uno inactivo, consistentes con la tabla RFM. "En riesgo/Inactivos" es el segmento más numeroso (39.4%) y coincide con la tasa de inactividad de la Parte 1 — objetivo natural de retención en la Parte 4.

Causa raíz confirmada desde 2025-Q2

-6.73 p.p.

Caída de margen neto en Trujillo (25.47% → 18.74%)


-5.57 p.p.

por mayor descuento promedio (5.8% → 13.0%)

-1.17 p.p.

por mayor costo de almacenamiento (1.26% → 2.43%)

Trujillo se deteriora solo desde abril 2025; la mezcla de categorías se descarta como causa.



Respuesta a la pregunta de negocio

- ▶ Patrones: estacionalidad de julio/diciembre y crecimiento sostenido del canal digital (25.3% → 55.5%) deben anticiparse en la planificación de inventario, personal y propuesta de valor digital.
- ▶ Segmentos: Champions + Leales concentran 78.9% de los ingresos con solo 40.9% de los clientes; "En riesgo/Inactivos" (39.4%) es la principal oportunidad de recuperación de ingresos.
- ▶ Causa raíz de Trujillo: confirmada — política de descuentos local (-5.57 p.p.) y sobrecosto de almacenamiento (-1.17 p.p.), no la mezcla de productos. Recomendación directa a Gerencia: revisar ambas palancas en esa plaza.
- ▶ Estos hallazgos alimentan directamente los modelos predictivos de demanda y churn de la Parte 3.

Predictivo, Prescriptivo, Power BI y Cierre

Anticipar demanda y clientes en riesgo de churn

1

OBJETIVO

Anticipar comportamientos relevantes del negocio mediante modelos predictivos, evitando fuga de información (leakage) entre features y target.

2

PREGUNTA DE NEGOCIO

¿Qué demanda se espera por categoría y periodo? ¿Qué clientes tienen mayor probabilidad de volverse inactivos?

3

MÉTODO

(1) Regresión de demanda categoría-ciudad-mes con partición temporal (train 2023-2024 / test 2025, TimeSeriesSplit).
(2) Clasificación de churn con corte de features al 2025-09-30 y target observado en el trimestre siguiente.

Gradient Boosting gana en ambos problemas




$$R^2 = 0.903$$

Modelo de demanda (test 2025, vs. $R^2=0.569$ del modelo base lineal)

$$\text{AUC-ROC} = 0.911$$

Modelo de churn (F1=0.811, precisión=0.848, recall=0.777)

Demanda: predicho vs. real cerca de la diagonal ideal. Churn: recencia y frecuencia dominan (SHAP).



Optimizar cuánto reponer, integrando Partes 2 y 3

1

OBJETIVO

Recomendar la mejor acción (cuánto inventario reponer por producto-tienda) mediante programación lineal, integrando el diagnóstico de sobrecosto de Trujillo (Parte 2) y la demanda predicha (Parte 3).

2

PREGUNTA DE NEGOCIO

¿Cuánto inventario mantener y qué política aplicar para maximizar el margen cumpliendo restricciones operativas?

3

MÉTODO

Formulación en PuLP: minimizar costo de almacenamiento + penalización por incumplir un nivel de servicio (NS) mínimo del 95%, sujeto a la capacidad física de cada una de las 8 tiendas físicas.

2 de 8 tiendas limitan el nivel de servicio

S/ 12,140

Costo total óptimo (S/ 7,570 de almacenamiento)



86.55%

Nivel de servicio efectivo logrado (meta: 95%)

2 / 8

tiendas con capacidad efectivamente restrictiva

Lima-T002 y Cusco-T010 quedan restringidas por capacidad: la palanca correcta es invertir en capacidad.






VISUALIZACIÓN
EN POWER BI

01 – Importar datos y transformación

1. Cambio de “null” por “0”, cambio de “blank” por “Desconocido”. Verificación de tipo de datos.

	Date	Customer	Item	Units	Cost
1	10/14/2011	Red Rock Mountain Tours	Gadgets	100	
2	3/17/2011	BlazerFire	Sprockets	69	
3	8/15/2011	Managec Group	Sprockets	74	
4	8/23/2011	CrossCountry Airways	Gadgets	30	1
5	6/11/2011	The Grand	Widgets	63	1
6	12/18/2011	Vanessa's Deli	Sprockets	35	
7	9/24/2011	CrossCountry Airways	Widgets	19	1
8	1/1/2011	Imagenie	Cogs	17	
9	2/26/2011	WeekendBreak Airways	Sprockets	82	
10	7/21/2011	Gleeson Associates	Sprockets	48	
11	6/7/2011	Imagenie	Gadgets	58	1
12	2/20/2011	Portage Airlines	Sprockets	80	
13	5/6/2011	Sonical Electronics	Widgets	51	
14	11/10/2011	Poseidon Bank	Sprockets	51	1
15	3/18/2011	Red Rock Mountain Tours	Gadgets	70	
16	8/10/2011	WeekendBreak Airways	Widgets	47	
17	7/25/2011	Poseidon Bank	Cogs	32	
18	6/15/2011	WeekendBreak Airways	Cogs	63	1
19	12/20/2011	Sonical Electronics	Gadgets	25	1
20	1/28/2011	Callinsure	Gadgets	85	
21	7/12/2011	Talk2uL8r	Cogs	95	1




2. Supervisión y corrección de algunas relaciones



01 – Importar datos y transformación

3. Se creó la tabla “Calendario” y se configuró como tabla de fechas. Se creó la jerarquía Año → trimestre → Mes

4. Creación de la tabla “_Medidas” para todas las medidas agregadas. Tabla para mantener el orden



02 - Medidas

▼  _Medidas 

 % Crecimiento MoM

 % Crecimiento YoY

 % Margen

 Clientes Activos

 Clientes Inactivos

 Clientes Nuevos

 Costo Almacenamiento

 Costo Total

 Descuento Promedio %


 Margen Bruto

 Margen Simulado

 N Transacciones

 Rotación Inventario

¿cuánto vendemos y cómo compra el cliente?
¿ganamos dinero y por qué se cae en Trujillo?
¿cuántos clientes activos y cuántos se están yendo?
¿vamos mejor o peor que antes?
¿cuánto nos cuesta almacenar y qué tan bien rota?
¿qué pasaría si cambio la política de descuento?

▼  Descuento Simulado 

 Descuento Simulado

 Descuento Simulado Value

 Stock Final 

 Tasa de Inactividad %

 Ticket Promedio

 Titulo Dinamico

 Total Clientes


 Unidades Vendidas

 Ventas Año Anterior

 Ventas Mes Anterior

 Ventas Totales

 Ventas YTD



CONCLUSIONES GENERALES

- Se integran las cuatro etapas analíticas en un mismo hilo de negocio. El ciclo analítico (descriptivo → diagnóstico → predictivo → prescriptivo)
- El 39.4% de clientes "en riesgo/inactivos" (Parte 2) coincide con el segmento que el modelo de churn (AUC=0.91, Parte 3) puede anticipar mensualmente para dirigir campañas de retención.
- La caída de margen en Trujillo queda visible, explicada y monitoreable.
- Un tercio de los clientes sostiene el negocio, y el segmento en riesgo es la gran oportunidad.

Gracias